

Avaliação do Modelo de Visão Computacional, YOLOv11-nano, para Detecção de Árvores

Matheus Duarte da Silva
Universidade de Brasília (UnB)
Departamento de Ciências da Computação

Abstract—This paper presents a performance evaluation of the modern object detector YOLOv11, specifically its YOLOv11-nano variant, for the task of automated individual tree crown detection and counting in complex urban environments. Using the public dataset from Campo Grande, comprising 3,382 annotated tree crowns and structured under a 5-fold cross-validation scheme. The model achieved an average precision of $AP_{50} = 0.695 \pm 0.012$ and an $AP_{50-95} = 0.365$, outperforming the average of anchor-free approaches in the literature and demonstrating a generational leap of over 10 percentage points compared to YOLOv3. In addition to its highly competitive accuracy—positioning itself just 0.8% below the benchmark leader—the model stood out for its excellent computational efficiency, recording an average inference time of 9.74 ms per image on a Tesla T4 GPU. The findings confirm the viability of state-of-the-art one-stage algorithms for large-scale, real-time urban environmental monitoring.

Index Terms—Object Detection, Deep Learning, YOLO, Remote Sensing, Tree Counting, Computer Vision

Resumo—Este trabalho apresenta uma avaliação de desempenho do detector de objetos YOLOv11, especificamente em sua versão YOLOv11-nano, na tarefa de detecção e contagem de copas de árvores em ambientes urbanos complexos. Utilizando o conjunto de dados público de Campo Grande, composto por 3.382 copas anotadas e estruturado em uma validação cruzada de 5-folds. O modelo alcançou uma precisão média de $AP_{50} = 0.695 \pm 0.012$ e $AP_{50-95} = 0.365$, superando a média das abordagens *anchor-free* da literatura e demonstrando um salto geracional superior a 10 pontos percentuais em relação ao YOLOv3. Além da alta competitividade em acurácia, ficando apenas 0,8% abaixo do líder do benchmark base, o modelo destacou-se pela excelente eficiência computacional, registrando um tempo médio de inferência de 9,74 ms por imagem em uma GPU Tesla T4. Os resultados confirmam a viabilidade de algoritmos de estágio único de última geração para o monitoramento ambiental urbano em larga escala e em tempo real.

Palavras-chave—Detecção de Objetos, Deep Learning, YOLO, Sensoriamento Remoto, Contagem de Árvores, Visão Computacional

I. INTRODUÇÃO

O crescimento acelerado da população em áreas urbanas traz diversos desafios, especialmente quando não é acompanhado por um planejamento adequado. A expansão do espaço urbano, muitas vezes realizada de forma desordenada, tende a desconsiderar áreas naturais existentes nos arredores das cidades, o que impacta negativamente o meio ambiente e, consequentemente, a qualidade de vida da população [1]. Esses impactos podem se manifestar por meio de fenômenos como ilhas de calor, enchentes e perda de biodiversidade [2], [3]. Em regiões com presença de rios e afluentes, é possível observar

que a urbanização contribui para a poluição hídrica e períodos de seca [4].

A arborização urbana e a preservação das áreas naturais são estratégias essenciais para a mitigação desses problemas. As árvores urbanas oferecem uma série de benefícios ambientais, como a absorção de poluentes atmosféricos e particulados e a regulação térmica e hídrica. Além de proporcionarem sombra, conforto ambiental e embelezamento da paisagem, as árvores desempenham um papel vital na saúde física e mental da população [2], [3], [5].

Apesar de ter sua importância reconhecida, o monitoramento e o cuidado de árvores em áreas urbanas ainda são tarefas extremamente desafiadoras. Quando realizadas manualmente, exigem alto custo financeiro e tempo, devido à grande quantidade e à ampla dispersão dos exemplares na malha urbana. Nesse contexto, o Sensoriamento Remoto aliado à Inteligência Artificial surge como uma alternativa promissora. Especificamente, técnicas de *Deep Learning* (Aprendizado Profundo), uma subárea da inteligência artificial capaz de extrair padrões complexos de grandes volumes de dados, aplicadas a imagens aéreas de alta resolução têm revolucionado o monitoramento ambiental. Modelos de detecção de objetos podem automatizar esse processo ao “aprender” a localizar e desenhar caixas delimitadoras (*bounding boxes*) ao redor das copas das árvores, reduzindo drasticamente o esforço humano na catalogação da grande variedade de árvores que podem existir num mesmo espaço.

Dentro da área de detecção de objetos, diferentes arquiteturas têm sido propostas. Zamboni et al. [6] realizaram um grande estudo comparativo com 21 modelos para a detecção de árvores, dividindo em duas principais categorias:

- ***anchor-based***: método tradicional que utiliza de caixas com dimensões pré-definidas, chamadas de “âncoras”, para procurar os objetos
- ***anchor-free***: métodos mais recentes que prediz a localização dos objetos diretamente a partir de pontos-chave ou centros, sem depender de formas pré-fixadas.

Os resultados indicaram que os modelos *anchor-free* lidam melhor com a irregularidade e sobreposição das copas, com destaque para o modelo FSAF, que obteve $AP_{50} = 0.701$, superando métodos amplamente utilizados na indústria, como Faster R-CNN e RetinaNet.

A área de Visão Computacional, no entanto, avança em ritmo acelerado. Em 2024, a Ultralytics lançou o **YOLOv11**, uma nova versão da família de detectores *You Only Look Once* (YOLO). Diferente de arquiteturas complexas de dois

estágios, os modelos YOLO são detectores *one-stage* (de estágio único). Isso significa que eles processam a imagem inteira de uma só vez em uma única passagem pela rede neural, prevendo simultaneamente o que é o objeto (classificação) e onde ele está (localização). Essa abordagem foca em um ótimo equilíbrio entre alta velocidade de processamento em tempo real e precisão [7], [8].

Diante desse avanço tecnológico, este trabalho investiga a aplicação do YOLOv11-nano, uma versão menor do modelo principal, na detecção de copas de árvores individuais, utilizando o mesmo conjunto de dados urbanos de Campo Grande, Brasil, avaliado por Zamboni et al. [6]. O objetivo principal é avaliar se um modelo moderno e leve de estágio único consegue superar ou empatar com os resultados dos melhores modelos *anchor-free* da literatura, oferecendo ganhos em eficiência computacional.

As principais contribuições deste trabalho são:

- A adaptação do pipeline experimental do estudo de referência [6] para treinar e validar a nova arquitetura YOLOv11-nano [8] no contexto florestal urbano;
- Uma análise quantitativa baseada em validação cruzada 5-fold, garantindo confiabilidade estatística na comparação dos resultados obtidos com os modelos do estado da arte.

O restante do artigo está organizado da seguinte forma: a Seção II discute trabalhos correlatos e os desafios técnicos da área; a Seção III descreve o conjunto de dados e os procedimentos metodológicos adotados; a Seção IV apresenta a análise quantitativa e qualitativa dos resultados alcançados; e, por fim, a Seção V expõe as considerações finais e apontamentos para trabalhos futuros.

II. TRABALHOS RELACIONADOS

A detecção automatizada de árvores individuais tornou-se uma área de pesquisa relevante em aplicações ambientais, agrícolas e de planejamento urbano. O avanço de técnicas de *Deep Learning*, aliado à crescente disponibilidade de imagens aéreas de alta resolução, tem impulsionado o desenvolvimento de soluções robustas para este desafio. Entre as arquiteturas mais investigadas, destacam-se os modelos de detecção de objetos como Faster R-CNN, RetinaNet e as diversas variantes da família YOLO (You Only Look Once).

Neste contexto, o trabalho de Zamboni et al. [6] — base para este projeto — realizou uma análise comparativa extensiva de 21 métodos, estabelecendo um importante benchmark para a detecção de árvores em ambientes urbanos. Para contextualizar a nossa contribuição, analisamos a seguir outros estudos que abordam desafios semelhantes.

Beloii et al. [9] exploraram o uso da arquitetura Faster R-CNN para detectar e classificar quatro espécies arbóreas em florestas temperadas na Suíça, utilizando imagens aéreas RGB. O estudo demonstrou que a abordagem multi-espécies foi eficaz mesmo em cenários com grande sobreposição de copas e iluminação variada, alcançando um F1-score de 0.92 para a espécie minoritária *P. sylvestris* e mantendo um desempenho estável para as demais. A pesquisa reforça a viabilidade de modelos de dois estágios para mapear espécies em florestas com estruturas complexas.

Em um cenário agrícola, Hnida et al. [10] propuseram um modelo avançado para a detecção multiescala de copas de oliveiras em ortofotos de alta resolução capturadas por VANTs (Veículos Aéreos Não Tripulados). A arquitetura, que incorporou componentes como CSPNet, FPN e PAN, alcançou um notável mAP_{50} de 94,0% e F1-score de 91,3%. Embora focado na agricultura de precisão, o estudo aborda desafios de detecção — como variações de escala e sobreposição de objetos — que são diretamente análogos aos encontrados em ambientes urbanos.

Os trabalhos mencionados demonstram o sucesso de arquiteturas complexas em cenários específicos. No entanto, há uma necessidade contínua de avaliar modelos mais recentes e eficientes, como os da família YOLO, que são projetados para otimizar o balanço entre velocidade e acurácia. Este estudo se insere nesta lacuna, propondo a avaliação do YOLOv11 [7], [8], [11], um detector de estágio único de alta eficiência. Ao aplicá-lo ao benchmark de Zamboni et al., investigamos se esta nova arquitetura pode oferecer um desempenho competitivo ou superior aos métodos do estado da arte já analisados para a arborização urbana.

III. METODOLOGIA

Essa seção detalha os procedimentos experimentais adotados para a avaliação do detector de objetos. A estrutura abrange desde a descrição e preparação do conjunto de dados, passando pela justificativa da arquitetura do modelo escolhido, até as configurações de treinamento e a definição matemática e conceitual das métricas de performance.

A. Conjunto de Dados e Preparação

O estudo utilizou o conjunto de dados público disponibilizado por Zamboni et al. [6]. Originalmente, os dados consistem em duas ortoimagens RGB da área urbana de Campo Grande, Brasil. As imagens possuem um *Ground Sample Distance* (GSD) de 10 cm, o que significa que cada pixel na imagem representa um quadrado de 10×10 cm no mundo real. Este alto nível de resolução espacial é um fator muito importante na detecção das áreas escolhidas, pois permite distinguir bordas e texturas em copas de árvores que se sobrepõem.

Para viabilizar o treinamento e a inferência na rede neural, as imagens originais de grandes proporções foram particionadas em 220 recortes menores (*patches*) de 512×512 pixels, resultando em uma área coberta de aproximadamente 2621,44 m² por patch. Ao todo, **3.382 copas de árvores** foram manualmente anotadas por especialistas utilizando retângulos delimitadores (*bounding boxes*), servindo como verdade de campo (*ground-truth*) para o modelo.

Para garantir que a avaliação seja robusta e não sofra com viés de amostragem, ou *overfitting*, o dataset original foi mantido sob a estrutura de validação cruzada de 5-folds. Neste método, os dados são divididos em cinco subconjuntos iguais; o modelo é treinado cinco vezes, e a cada iteração, um subconjunto diferente é separado exclusivamente para teste.

Antes do treinamento, as anotações passaram por um pré-processamento para conversão ao padrão esperado pela arquitetura YOLO. Este formato exige que as coordenadas espaciais

de cada objeto ($x_{centro}, y_{centro}, largura, altura$) sejam normalizadas em uma escala de 0 a 1 em relação às dimensões da imagem, garantindo que o modelo aprenda características espaciais invariantes à escala.

B. Modelo Utilizado e Transferência de Aprendizado

O modelo selecionado para a detecção foi o **YOLOv11-nano**, a versão mais recente da família *You Only Look Once* para o ano de 2024. Diferente de abordagens clássicas que geram propostas de regiões para depois classificá-las, os modelos de dois estágios, os modelos YOLO são algoritmos de estágio único (*one-stage*). Assim, eles modelam a detecção como um problema único de regressão, prevendo simultaneamente as classes e as coordenadas das caixas diretamente da imagem completa, o que fornece velocidade extrema ao processo [11]. A versão *nano* foi escolhida especificamente por ser a variante com menor custo computacional, ideal para aplicações escaláveis em hardwares com recursos limitados.

A arquitetura do YOLOv11 incorpora inovações essenciais, com destaque para o módulo C2PSA (*Convolutional block with Parallel Spatial Attention*). Este mecanismo de "atenção espacial" permite que a rede neural priorize os pixels mais relevantes da imagem (ex: texturas de folhas e formatos arredondados) em detrimento do ruído de fundo (ex: asfalto e telhados) [7], [11].

Em vez de inicializar a rede com pesos aleatórios, adotou-se a técnica de *Transfer Learning* (Aprendizado por Transferência). Um modelo previamente treinado na base de dados genérica COCO (`yolo11n.pt`), que já possui a capacidade de reconhecer contornos, formas e texturas básicas, foi refinado (*fine-tuned*) para a tarefa específica de detecção de copas de árvores. O treinamento foi executado através da biblioteca *Ultralytics*, no ambiente do Google Colab, utilizando a GPU T4.

C. Configuração Base

Buscando a reprodutibilidade do experimento e o alinhamento com o estudo de referência [6], o treinamento foi replicado nas cinco execuções (folds) mantendo-se os seguintes hiperparâmetros fixos:

- **Épocas (Epochs):** 24.
 - Uma época representa uma passagem completa de todo o conjunto de dados de treinamento pela rede neural.
- **Tamanho da Imagem (Input Size):** Imagens redimensionadas e padronizadas em 512×512 pixels.
- **Otimizador e Taxa de Aprendizagem:** Foram mantidos os parâmetros padrão da biblioteca *Ultralytics*.

D. Métricas de Avaliação

A quantificação do sucesso do modelo baseou-se na métrica de *Average Precision* (AP), que é a métrica mais recomendada na área de detecção de objetos. Para compreender seu cálculo, é preciso definir a lógica de acertos e erros do modelo, fundamentada no *Intersection over Union* (IoU).

O IoU mede o grau de sobreposição geométrica entre a predição do modelo e a anotação real (*ground-truth*). Matematicamente, é a área de interseção dividida pela área de união entre as duas caixas. Dado um limiar de exigência (ex: IoU de 0.5, significando pelo menos 50% de sobreposição), as detecções são classificadas em:

- **Verdadeiro Positivo (TP - True Positive):** O modelo detectou uma árvore em um local correto ($\text{IoU} \geq \text{limiar}$).
- **Falso Positivo (FP - False Positive):** O modelo indicou a presença de uma árvore onde não há, ou a caixa delimitadora ficou muito deslocada da real ($\text{IoU} < \text{limiar}$).
- **Falso Negativo (FN - False Negative):** Uma árvore que existe no mundo real, mas o modelo não conseguiu identificar.

Com estes contadores, é notado um *trade-off* entre **Precisão** e **Recall** (Sensibilidade). A Precisão responde "de todas as árvores que o modelo detectou, quantas eram realmente árvores?". Enquanto o Recall responde "de todas as árvores que existem, quantas o modelo conseguiu achar?".

$$\text{Precisão} = \frac{TP}{TP + FP} \quad (1)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2)$$

A **Average Precision (AP)** sintetiza essa relação ao calcular a área sob a curva Precisão-Recall. Ao plotar essa curva utilizando diferentes níveis de confiança, a AP fornece uma avaliação robusta que pune tanto o excesso de alarmes falsos quanto a omissão de objetos. Neste trabalho, utilizou-se:

- **AP₅₀:** Métrica mais comum, que exige apenas um limiar de IoU de 50% para considerar a localização como correta.
- **AP₅₀₋₉₅:** Uma métrica mais rigorosa que verifica a exatidão das caixas delimitadoras.
 - Ela representa a média das APs calculadas em 10 diferentes limiares de IoU, escalonados de 0.50 até 0.95, com passos de 0.05.

Os resultados apresentados nas seções seguintes representam a média aritmética e o respectivo desvio padrão das execuções sobre os cinco conjuntos de teste da validação cruzada.

IV. RESULTADOS E DISCUSSÃO

A análise a seguir apresenta os resultados quantitativos, comparando com o benchmark de referência, e discute o comportamento do modelo durante o processo de treinamento.

A. Análise Quantitativa e Comparativa

Para cada um dos cinco folds, o modelo foi treinado por 24 épocas e avaliado em seu respectivo conjunto de teste. A Tabela I sumariza os valores de performance obtidos para as métricas de AP_{50} e AP_{50-95} .

O modelo alcançou um AP_{50} médio de **0.695 ± 0.012**, um resultado que demonstra alta consistência entre os diferentes subconjuntos de dados. Este valor posiciona o YOLOv11n

Tabela I
RESULTADOS DE PERFORMANCE DO YOLOv11n POR FOLD

Fold	AP ₅₀	AP ₅₀₋₉₅
0	0.690	0.370
1	0.696	0.360
2	0.686	0.360
3	0.715	0.380
4	0.686	0.353
Média	0.695	0.365
Desvio Padrão	0.012	0.010

como um dos modelos de melhor desempenho, ficando apenas ****0.8%**** abaixo do líder do benchmark, o modelo FSAF ($AP_{50} = 0.701$). É visível que a performance do YOLOv11n supera a média dos modelos *anchor-free* ($AP_{50} = 0.686$) e também o seu predecessor, o YOLOv3 ($AP_{50} = 0.591$), em mais de 10 pontos percentuais, apontando um avanço geracional significativo [6].

O resultado médio de AP_{50-95} de **0.365** indica que o modelo mantém uma boa precisão de localização mesmo em limiares de IoU mais rigorosos, sugerindo que as caixas delimitadoras preditas são bem ajustadas aos objetos reais.

B. Análise do Comportamento do Treino e Discussão

A escolha de treinar por 24 épocas, em conjunto à metodologia do artigo base, provou ser suficiente para alcançar resultados satisfatórios. A análise das curvas de treino e validação, apresentadas na Fig. 1 para um dos folds, mostra um padrão consistente em todas as cinco execuções. As curvas de perda (*loss*) decrescem rapidamente e as métricas de validação, como o AP_{50} , sobem de forma acentuada nas primeiras 15 épocas, indicam um aprendizado eficiente.




Figura 1. Curvas de treino e validação para o Fold 0

Embora as curvas comecem a estabilizar, elas não atingem um platô completo, sugerindo que um treinamento mais longo poderia refinar o modelo e, potencialmente, levar a ganhos incrementais de performance.

Uma análise mais profunda da relação entre o score F1 e o limiar de confiança do modelo é apresentada na Fig. 2. Consistentemente entre os folds, o pico de performance F1 (entre 0.66 e 0.69) é alcançado com um limiar de confiança relativamente baixo, em torno de 0.27. Esta informação é valiosa para otimizar a aplicação prática do modelo, pois permite definir um limiar de decisão que equilibra de forma ideal a precisão e o recall das detecções.




Figura 2. Curva F1-Confiança para o Fold 3

Assim, a discussão quantitativa e a análise do comportamento do treino mostram que o YOLOv11n não é apenas competitivo em termos de acurácia, mas também um modelo bem-comportado e previsível. Apesar de sua leveza, ele demonstrou uma capacidade notável de aprender características complexas das copas das árvores, rivalizando com arquiteturas mais pesadas e se estabelecendo como uma ferramenta poderosa e eficiente para aplicações de sensoriamento remoto urbano.

C. Discussão e Análise Qualitativa

Um dos achados mais relevantes deste estudo é a demonstração de que a performance de detecção do YOLOv11n, conforme detalhado na seção anterior, é acompanhada por uma notável eficiência computacional. Apesar de ser uma arquitetura leve, com 100 camadas, aproximadamente 2.6 milhões de parâmetros e 6.5 GFLOPs de custo computacional [7], [8], [11], o modelo demonstrou um desempenho quantitativo que rivaliza com arquiteturas mais complexas.

Esta eficiência é confirmada pelo tempo de inferência, que foi medido para cada fold no conjunto de teste em uma GPU Tesla T4. A Tabela II apresenta estes valores, que resultaram em uma média de apenas **9.74 ms** por imagem.

Tabela II
TEMPO DE INFERÊNCIA DO YOLOv11n POR IMAGEM EM CADA FOLD

Fold	Tempo de Inferência (ms)
0	12.5
1	15.3
2	8.0
3	6.8
4	6.1
Média	9.74
Desvio Padrão	3.98

A combinação de alta acurácia (AP_{50} de 0.695) com baixa latência de inferência torna o YOLOv11n um forte candidato para aplicações em larga escala e em tempo real, onde o processamento rápido de grandes volumes de imagens é um requisito fundamental. É importante notar a variabilidade no tempo de inferência entre os folds, indicada pelo desvio padrão de 3.98 ms. Essa flutuação pode ser atribuída tanto a variações no ambiente de execução quanto à complexidade distinta das imagens em cada conjunto de teste.

Do ponto de vista qualitativo, a análise das predições revela que o modelo é particularmente eficaz na detecção de árvores

isoladas ou em grupos de baixa densidade, independentemente do tamanho da copa. No entanto, o principal desafio, em linha com as observações do estudo de referência [6], reside em áreas de alta densidade de vegetação, onde as copas se sobrepõem. Nestes cenários complexos, o modelo por vezes agrupa múltiplas árvores em uma única detecção ou falha em identificar árvores menores sob a sombra de outras maiores.

D. Limitações e Trabalhos Futuros

Embora os resultados deste estudo sejam promissores, é importante reconhecer suas limitações, que, por sua vez, abrem caminhos para pesquisas futuras.

As principais limitações identificadas são:

- **Escopo da Arquitetura:** A avaliação se restringiu à variante "nano" do YOLOv11. Embora eficiente, ela pode não representar o potencial máximo de acurácia da família de modelos.
- **Rigor Estatístico:** Não foram realizadas análises estatísticas formais, como o teste ANOVA com correção de Holm-Bonferroni, para determinar se as diferenças de performance entre o YOLOv11n e os modelos de topo do benchmark são estatisticamente significativas.
- **Medição de Eficiência:** O tempo de inferência foi medido em um ambiente de nuvem (Google Colab), que pode apresentar flutuações. Um benchmark formal em hardware padronizado seria necessário para uma avaliação de eficiência mais rigorosa.

Com base nestes pontos, os seguintes trabalhos futuros são propostos:

- Avaliar o desempenho de variantes mais robustas do YOLOv11 (e.g., YOLOv11-s ou YOLOv11-m) para quantificar o *trade-off* entre acurácia e custo computacional.
- Realizar um benchmark de eficiência mais detalhado, incluindo métricas como FPS (Frames Per Second) e latência em diferentes hardwares.
- Estender a análise para outros ambientes urbanos e tipos de vegetação, utilizando novos conjuntos de dados para avaliar a capacidade de generalização e a robustez do modelo.

V. CONCLUSÃO

Este trabalho se propôs a avaliar a eficácia do detector de objetos YOLOv11n para a tarefa de detecção de árvores individuais em imagens aéreas urbanas, contextualizando sua performance frente ao benchmark realizado por Zamboni et al. [6]. Através de uma metodologia rigorosa de validação cruzada de 5-folds e da manutenção de consistência com os parâmetros do estudo de referência, foi possível posicionar com segurança esta nova arquitetura para esse tipo de aplicação.

Os resultados quantitativos demonstraram que, mesmo em sua versão mais compacta ("nano"), o YOLOv11n alcançou um desempenho notável, registrando um AP_{50} médio de **0.695**. Este valor não apenas supera a média dos modelos *anchor-free* avaliados no estudo original, como também rivaliza diretamente com as arquiteturas de topo, ficando a apenas 0,8% do modelo líder. Além da extrema competitividade em

termos de acurácia, o modelo teve um grande destaque por sua alta eficiência computacional, alcançando um tempo de inferência médio de apenas 9,74 ms por imagem.

A principal contribuição deste estudo é a comprovação prática de que arquiteturas modernas de *one-stage* conseguem atingir um patamar de performance comparável a modelos bidirecionais complexos e computacionalmente caros, sem sacrificar a velocidade de processamento. Do ponto de vista prático, isso sinaliza um avanço fundamental para o monitoramento ambiental. A combinação de arquitetura leve e alta precisão viabiliza o processamento rápido de enormes volumes de ortoimagens (frequentemente gigabytes de dados gerados por satélites ou VANTs), tornando-se ideal para operações em larga escala.

Como trabalhos futuros, recomenda-se a avaliação de variantes mais robustas da família (como o YOLOv11-s ou YOLOv11-m) ou as novas versões do modelo, para quantificar com exatidão a relação entre ganho de acurácia e custo computacional, além da realização de testes em conjuntos de dados de diferentes cidades para aferir a generalização do modelo frente a novos ambientes urbanos.

REFERÊNCIAS

- [1] B. Güneralp and K. C. Seto, “Environmental impacts of urban growth from an integrated dynamic perspective: A case study of shenzhen, south china,” *Global Environmental Change*, 2008. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0959378008000587>
- [2] F. Angeoletto, T. E. P. N. Duarte, J. W. M. C. Santos, F. F. Silva, J. F. C. Bohrer, and L. Massad, “Reflexões sobre arborização urbana: desafios a serem superados para o incremento da arborização urbana no Brasil,” *Revista em Agronegócio e Meio Ambiente*, 2018. [Online]. Available: https://www.researchgate.net/publication/324068470_REFLEXOES_SOBRE_ARBORIZACAO_URBANA_DESAFIOS_A_SEREM_SUPERADOS_PARA_O_INCREMENTO_DA_ARBORIZACAO_URBANA_NO_BRASIL
- [3] Universidade Federal de Santa Maria. (2024) A importância da arborização urbana para cidades sustentáveis. Acesso em: 04 jul. 2025. [Online]. Available: <https://www.ufsm.br/unidades-universitarias/ccne/2024/06/20/a-importancia-da-arborizacao-urbana-para-cidades-sustentaveis>
- [4] R. C. da Silva Menezes e George Rembrandt Gutlich. (2015) Apontamentos do crescimento urbano e o desafio da preservação ambiental. Acesso em: 04 jul. 2025. [Online]. Available: <https://www.revistaespacios.com/a16v37n08/16370810.html>
- [5] C. T. C. e Samara Simon Christmann e Tarcísio Dorn de Oliveira. (2014) Arborização urbana: Importância e benefícios no planejamento ambiental das cidades. Acesso em: 04 jul. 2025. [Online]. Available: <https://tinyurl.com/2485uhar>
- [6] P. Zamboni, J. M. Junior, J. de Andrade Silva, G. T. Miyoshi, E. T. Matsubara, K. Nogueira, and W. N. Gonçalves, “Benchmarking Anchor-Based and Anchor-Free State-of-the-Art Deep Learning Methods for Individual Tree Detection in RGB High-Resolution Images,” *Remote Sensing*, 2021. [Online]. Available: <https://www.mdpi.com/2072-4292/13/13/2482>
- [7] Ultralytics. (2024) Yolov11 documentation. Acesso em: 04 jul. 2025. [Online]. Available: <https://docs.ultralytics.com/models/yolo11/>
- [8] G. Jocher and J. Qiu. (2024) Ultralytics yolo11. [Online]. Available: <https://github.com/ultralytics/ultralytics>
- [9] M. Beloiu, L. Heinzmann, N. Rehush, A. Gessler, and V. C. Griess, “Individual tree-crown detection and species identification in heterogeneous forests using aerial rgb imagery and deep learning,” *Remote Sensing*, 2023. [Online]. Available: <https://www.mdpi.com/2072-4292/15/5/1463>
- [10] Y. Hnida, M. A. Mahraz, A. Yahyaouy, A. Achebour, J. Riffi, and H. Tairi, “Enhanced multi-scale detection of olive tree crowns in uav orthophotos using a deep learning architecture,” *Smart Agricultural Technology*, 2025. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2772375525003582>
- [11] R. Khanam and M. Hussain, “Yolov11: An overview of the key architectural enhancements,” 2024. [Online]. Available: <https://arxiv.org/abs/2410.17725>

APÊNDICE A

REPOSITÓRIO DO PROJETO

O código-fonte, os experimentos e os arquivos utilizados neste trabalho estão disponíveis no seguinte repositório público:

github.com/smmstakes/iaa-trabalho-2

O repositório contém:

- Notebook para treinamento e validação do YOLOv11;
- Scripts de preparação do conjunto de dados;
- Resultado dos treinamentos com seus gráficos e demais informações;
- Arquivo README.md com instruções para reprodução.